ACTIVIDAD 8

Monitorización y gobernanza del servicio de portafolios



Vértice AI Consulting · Convertimos datos en decisiones

Materia:	*Gestión de Proyectos de Inteligencia Artificial*
Actividad:	Actividad 8 · Módulo 3 / Semana 10 · Temas 19 y 20
Alumno(a):	*Eduardo Aburto Angulo*
Matrícula:	*AL07182743*
Docente:	*M. en C. Luis Ariel Vázquez Piña*
Fecha de entrega:	5 de noviembre de 2026

Declaración de Uso de Inteligencia Artificial

El alumno debe indicar de manera honesta si utilizó herramientas de Inteligencia Artificial (IA) para el desarrollo de esta actividad. Completa la siguiente tabla:

Herramienta de IA utilizada	¿La usaste?	Propósito / Descripción de uso
ChatGPT / OpenAI	Sí	ChatGPT/Codex: apoyo en programación, ejecución de pruebas, simulaciones locales, documentación y revisión visual. Las mediciones proceden de ejecuciones reales con fallas inyectadas.
Claude (Anthropic)	Antecedentes	Herramienta mencionada en actividades previas; no se atribuye ejecución nueva en Actividad 8.
Gemini (Google)	Antecedentes	Herramienta mencionada en actividades previas; no se atribuye ejecución nueva en Actividad 8.
Copilot (Microsoft)	Antecedentes	Herramienta mencionada en actividades previas; no se atribuye ejecución nueva en Actividad 8.
Otra (especifica):	Antecedentes	Herramienta mencionada en actividades previas; no se atribuye ejecución nueva en Actividad 8.

Desarrollo de Contenido

Propósito y decisión operativa

Como banquero Sr., necesito saber cuándo una señal deja de ser confiable antes de incorporarla a una revisión de portafolio. En esta entrega implementé observabilidad para la API de clasificación de noticias de Fase II. Mi decisión es mantener la solución como laboratorio académico: las tres fallas simuladas se detectaron y recuperaron, pero la corrida completa incumplió el presupuesto de latencia. La recuperación no equivale a acreditar producción.

El objetivo verificable fue instrumentar métricas, logs y trazas; detectar tres incidentes mediante reglas persistentes; ejecutar respuestas reversibles y conservar evidencia en MLflow. Ejecuté 900 solicitudes HTTP en 15 ventanas de 60 observaciones. No usé datos de clientes reales ni ejecuté movimientos de inversión.

Continuidad y alcance

Conservé la SVM calibrada y el umbral 0.20 de Actividad 6. La clase positiva significa noticia negativa y el idioma soportado es inglés. Fase II aporta la API FastAPI. La referencia de código es b6ecb7a0e6b01ece989369b7b67178fe7d7cc2a4; el manifest del modelo permite comprobar sus bytes. Esta actividad evalúa la operación del servicio y no vuelve a seleccionar modelos con el test.

Utilicé 60 textos del test retrospectivo: 20 negativos y 40 no negativos, seleccionados con semilla 42. Repito esa muestra en cada ventana para aislar el efecto de las fallas. Las etiquetas son conocidas y la distribución no representa la cartera ni tráfico real. Las métricas del canario no sustituyen las del test completo de 452 registros.

Arquitectura implementada

El cliente envía solicitudes a la API local instrumentada. El middleware registra estado, duración, versión y trace_id sin guardar noticias ni claves. El monitor agrega ventanas, calcula SLI y PSI y dispara acciones locales. MLflow registra parámetros, métricas por paso y artefactos; Streamlit actualiza la vista cada tres segundos. Los spans padre e hijo son locales en JSONL; no implementé un Collector de OpenTelemetry ni propagación entre servicios.

Indicadores y contratos de medición

Indicador	Definición y uso
Disponibilidad	Respuestas HTTP 200 / solicitudes válidas del canario. Timeouts y respuestas no exitosas consumen presupuesto.
Latencia	Tiempo cliente de ida y vuelta; p95 por ventana. SLI: proporción de solicitudes exitosas con duración ≤250 ms.
Tráfico y recursos	Solicitudes / segundo; memoria RSS y CPU del proceso. 512 MB es presupuesto de planificación, no límite impuesto.
Calidad	Precisión, recall y F1 de noticia negativa, sólo sobre respuestas exitosas con etiqueta. Mínimo 15 negativos por ventana.
Drift	PSI de longitud en palabras frente al canario inicial; bins 0,10,20,30,50,1000000 y suavizado +0.5.
Logs y trazas	Timestamp, ruta, método, estado, duración, modo y revisión. trace_id une solicitud, log y spans con padre, inicio y fin.

El campo exportado server_errors conserva su nombre histórico, pero cuenta cualquier respuesta no exitosa del canario, no sólo errores 5xx. El control de laboratorio exige una clave distinta de la API y LAB_MODE=1. El proceso escucha sólo en loopback. Las pruebas comprueban que texto y claves no se filtran al log.

SLO y presupuesto de error

Definí SLO de disponibilidad de 99 % y SLO de latencia de 99 % de solicitudes ≤250 ms. Para N solicitudes, presupuesto permitido = N × (1 − SLO); consumo = número de solicitudes malas; saldo = permitido − consumo. Burn rate = fracción mala / (1 − SLO). Son ventanas por solicitudes del laboratorio, no ventanas mensuales de producción ni un SLA contractual.

En 900 solicitudes, cada presupuesto permite 9 eventos. La disponibilidad consumió cero. La latencia consumió 120: saldo −111 y cumplimiento agregado 86.67 %. El burn agregado fue 13.33 veces la tasa permitida. El servicio volvió a su condición normal después de la intervención, pero ese consumo permanece registrado.

Alertas y reducción de ruido

Regla	Disparador y prioridad	Respuesta
Disponibilidad	Burn >2 en dos ventanas de 60; P1	Diagnóstico y rollback de configuración; escalamiento si persiste
Latencia	Burn >2 en dos ventanas de 60; P2	Restaurar modo normal y verificar dos ventanas
Calidad	Recall <0.75 o F1 <0.65 con etiquetas suficientes; P2	Revertir salida alterada y revisar calidad
Drift	PSI >0.20 durante dos ventanas; P3	Cuarentena del lote sintético y revisión local

La persistencia evita avisar por un único incumplimiento. La deduplicación emite una sola apertura por regla activa; exige dos ventanas sanas para cerrar. Si faltan etiquetas, una alerta de calidad permanece abierta. Un P1 no queda silenciado por un P2. El mínimo de 60 solicitudes evita interpretar lotes incompletos. Los umbrales son decisiones de laboratorio y requieren recalibración con historia operativa.

El motor observó seis ventanas que habrían generado aviso individual y emitió tres aperturas: reducción del 50 % frente a esa política simple. No infiero una tasa de falsos positivos ni una validación estadística con tres incidentes. En producción incorporaría ventanas temporales cortas y largas y guardias; aquí la persistencia usa dos ventanas consecutivas de solicitudes.

Data drift y límites del diagnóstico

Calculo PSI = suma de (q − p) × ln(q/p), usando proporciones suavizadas. El experimento repite ocho veces cada texto para desplazar la longitud. La alerta indica cambio de entrada, no prueba pérdida de capacidad predictiva. No cubre cambios semánticos de igual longitud, idioma, etiquetas ni concept drift. Para producción añadiría seguimiento de embeddings y calidad con etiquetas retrasadas, por segmentos y con tamaño muestral suficiente.

Dashboard para decidir

La vista Servicio presenta disponibilidad, p95, burn rate, presupuesto, tráfico y memoria. Modelo muestra precisión, recall, F1 y PSI. Incidentes permite examinar aperturas, cierres y pasos del runbook. Trazabilidad expone resumen, corrida MLflow y spans. Cuando el laboratorio está detenido, el tablero indica que muestra la última corrida; no presenta esos datos como tráfico vivo.

Respuesta automatizada y gobernanza

Los runbooks completos están en runbooks/README.md. Cada ejecución registra preparación, detección, diagnóstico, corrección, verificación y postmortem. RB01 restaura la configuración ante latencia; RB02 revierte la alteración simulada de probabilidades; RB03 aparta el lote de entrada alterado y registra escalamiento local. El rollback no cambia el artefacto del modelo. El reentrenamiento requiere diagnóstico, evaluación y autorización humana y no se ejecutó.

Si la corrección no recupera dos ventanas, el procedimiento mantiene el incidente abierto y escala al operador; no establece reintentos indefinidos. Los roles propuestos son operador MLOps para continuidad, propietario del modelo para validación y banquero para uso de señales. El ticket de escalamiento es un registro local, no un envío a un servicio externo de guardia.

Incidente	Detección s	Recuperación s	Estado
latency	43.457	0.291	resolved
degradation	0.295	0.268	resolved
drift	0.298	0.261	resolved

MTTD se mide desde inyección a detección y MTTR desde detección hasta cierre verificado. Las medias fueron 14.683 s y 0.273 s. La latencia tarda más en detectarse porque 120 solicitudes secuenciales acumulan el retraso inyectado de 350 ms; las otras fases corren rápidamente en el mismo host. Estos tiempos no son expectativas de recuperación para una operación distribuida.

Mantenimiento y deuda técnica

Versioné configuración y scripts, conservé hash de modelo, evidencia portable y pruebas de controles. MLflow usa SQLite local; cada reproducción obtiene una corrida distinta. La promoción productiva requeriría almacenamiento central de telemetría, autenticación y permisos por rol, retención, alertamiento a guardia, control transaccional de acciones y pruebas de carga. El laboratorio no debe exponerse como endpoint público.

Propongo revisar SLO y umbrales mensualmente con el propietario del servicio; ensayar runbooks tras cambios de modelo; conservar incidentes y decisiones en un registro auditado. La propuesta de retención es 30 días de telemetría operativa y 90 de incidentes, sujeta a política institucional. No se ha implementado borrado automático ni aprobación regulatoria.

Evidencia y conclusión

Entrego scripts ejecutables, nueve pruebas automatizadas, un verificador que recalcula métricas y correlaciona trazas, tres documentos y un tablero Streamlit. MLflow registró la corrida c0a8fa3f79b84eb4bec63d70b674bf32 con estado FINISHED. Las capturas y exportaciones se presentan en Evidencia de implementación; las cronologías en Simulación de incidentes.

Mi conclusión es que el prototipo permite detectar y atender las fallas ensayadas de forma trazable. Conservo explícitamente el incumplimiento agregado de latencia y los límites de la muestra. Mi criterio como banquero es detener el uso de una señal dudosa y solicitar revisión, antes de convertir un resultado técnico en una acción sobre el patrimonio de un cliente.

Contexto de negocio complementario

La continuidad del proyecto conserva 150 personajes ficticios con posiciones de 5 a 20 millones de pesos. Su función es didáctica: dar personalidad a escenarios sin usar datos reales. La comisión de 1 % por compra y 1 % por venta es un supuesto académico; no constituye una tarifa verificada de BBVA. Las comisiones de fondos dependen de documentación y series vigentes. No uso esos supuestos para medir éxito del monitor ni para recomendar cambios de fondos.

Fuentes y trazabilidad

Universidad Tecmilenio. Rúbrica Actividad 8 y temas 19 y 20, materiales proporcionados por el alumno. Temas 17 y 18 como continuidad de MLOps y despliegue.

MLflow. Tracking y Tracking API. https://mlflow.org/docs/latest/tracking/ y https://mlflow.org/docs/latest/tracking/tracking-api

Google SRE Workbook. Alerting on SLOs. https://sre.google/workbook/alerting-on-slos/

OpenTelemetry. Signals y Traces. https://opentelemetry.io/docs/concepts/signals/ y https://opentelemetry.io/docs/concepts/signals/traces/

Repositorio de entrega: https://github.com/eduardoaburtoa/actividad8-observabilidad-portafolios. Código de origen y manifest preservados; consulta técnica el 5 de noviembre de 2026.